Seguridad en Sistemas, Aplicaciones y el Big Data

Tema 10. Seguridad en big data

Índice

Esquema

Ideas clave

10.1. Introducción y objetivos

10.2. Arquitecturas big data

10.3. Arquitecturas Hadoop

10.4. Referencias bibliográficas

A fondo

Amazon Elastic Map Reduce

Microsoft Azure HDInsight

Implementación de seguridad en Hadoop con Apache Ranger

Apache Knox Gateway

Proyecto Rhino

Test

© Universidad Internacional de La Rioja (UNIR)

10.1. Introducción y objetivos

En el contexto del *big data,* los retos de seguridad adquieren una dimensión mayor debido al volumen masivo de datos, su variedad (estructurados, no estructurados, semiestructurados), la velocidad de generación y consumo y la heterogeneidad del ecosistema (múltiples fuentes, múltiples plataformas, múltiples consumidores). Por ello, asegurar las plataformas de *big data* no es solo cuestión de aplicar controles tradicionales, sino de adaptarlos y extenderlos para cubrir escenarios específicos de este entorno distribuido.

Un referente ampliamente aceptado para modelar arquitecturas de *big data* y pensar la integración de la seguridad y la privacidad es el *NIST Big Data Interoperability Framework*, en particular sus volúmenes de «Reference Architecture» (Volumen6) y «Security and Privacy» (Volumen4) que definen un tejido *(fabric)* de seguridad y privacidad que atraviesan todos los componentes de la arquitectura.

Este resumen adopta el enfoque del NIST como columna vertebral e incorpora, además, aportes recientes de la literatura para complementar los mecanismos de seguridad (autenticación, autorización, criptografía, auditoría, privacidad, gobernanza).

Los objetivos del estudio de la seguridad en big data son los siguientes:

- Analizar los principales componentes de una arquitectura de big data.
- Examinar un ejemplo de arquitectura big data, como Azure HDInsight.
- Las principales amenazas y vulnerabilidades de las arquitecturas big data.
- Analizar las principales medidas de seguridad y privacidad por implementar en arquitecturas big data.

© Universidad Internacional de La Rioja (UNIR)

10.2. Arquitecturas big data

En el contexto del *big data,* los retos de seguridad adquieren una dimensión mayor debido al **volumen masivo** de datos, su **variedad** (estructurados, no estructurados, semiestructurados), la velocidad de **generación** y consumo y la heterogeneidad del **ecosistema** (múltiples fuentes, múltiples plataformas, múltiples consumidores). Por ello, asegurar las plataformas de *big data* no es solo cuestión de aplicar controles tradicionales, sino de adaptarlos y extenderlos para cubrir escenarios específicos de este entorno distribuido.

Un referente ampliamente aceptado para modelar arquitecturas de *big data* y pensar la integración de la **seguridad** y la **privacidad** es el *NIST Big Data Interoperability Framework,* en particular sus volúmenes de «Reference Architecture» (Volumen6) y «Security and Privacy» (Volumen4) que definen un **tejido** *(fabric)* de seguridad y privacidad que atraviesan todos los componentes de la arquitectura (NIST, s. f.)

Este resumen adopta el enfoque del NIST como columna vertebral e incorpora, además, aportes recientes de la literatura para complementar los mecanismos de seguridad (autenticación, autorización, criptografía, auditoría, privacidad, gobernanza).

Arquitectura de referencia del NIST

El NIST define un modelo conceptual denominado NIST *big data reference architecture* (NBDRA), que identifica **roles, funciones** (tecnologías funcionales) y **tejidos** *(fabrics)* que atraviesan esas funciones (NIST, s. f.).

Los **roles principales** son:

- *Data provider* (proveedor de datos).
- *Big data framework provider* (proveedor del *framework*/plataforma).

© Universidad Internacional de La Rioja (UNIR)

- *Data consumer* (consumidor de datos).
- *Application provider* (proveedor de aplicaciones).
- *System orchestrator* (orquestador del sistema).
- *Framework provider* y *management fabric.*

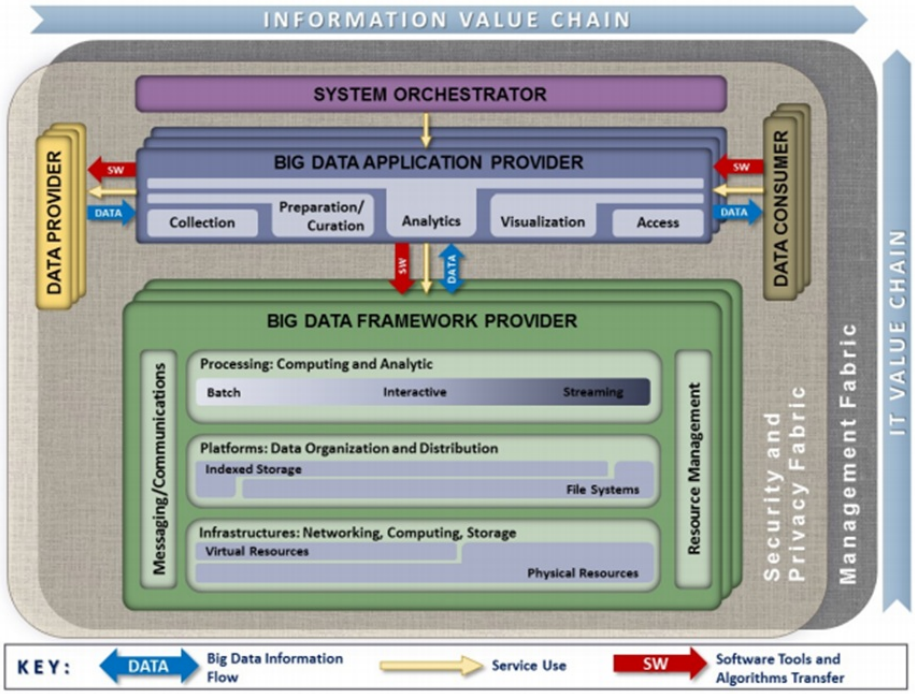


Figura 1. Modelo *big data* NBDRA. Fuente: Boyd, Chang y Levin, 2019.

Uno de los tejidos transversales es el *security and privacy fabric,* que integra **seguridad** y **privacidad** a lo largo de todas las funciones (ingestión, almacenamiento, procesamiento, análisis, presentación) (NIST, s. f.). Asimismo, existe el *management fabric,* que coordina tareas de **gestión, gobernanza, monitorización** y *orquestación* (NIST, s. f.).

© Universidad Internacional de La Rioja (UNIR)

Ideas clave

En la vista de funciones, el NBDRA se descompone en **componentes funcionales** (por ejemplo, ingesta, almacenamiento, procesamiento, recursos de metadatos, seguridad, etc.), que son sobre los que actúa el tejido de seguridad (NIST, s. f.).

La idea es que la seguridad no esté disociada ni sea un añadido al final, sino que sea u n **componente transversal** que deba permear cada capa y función de la arquitectura.

El tejido security & privacy

El volumen de seguridad del NIST (Volumen 4) define cómo ese tejido puede articular mecanismos de seguridad y privacidad en distintas **fases** del **ciclo de vida** de los datos, y establece una **taxonomía** de casos de **uso, amenazas** y **controles** (NIST, s. f.).

Entre los **aspectos tratados** por el tejido de seguridad:

- **Autenticación** y autorización distribuida.
- **Control de acceso** en múltiples niveles (datos, metadatos, API, rol/servicio).
- **Cifrado** en tránsito y en reposo.
- **Gestión** segura de **claves.**
- **Auditoría** y registro *(logging).*
- **Privacidad de datos:** anonimización, desidentificación, mecanismos de protección de la información personal.
- **Trazabilidad/linaje de datos***(data lineage).*
- **Forense de datos***(big data forensics).*
- **Gestión de riesgos** y cumplimiento normativo.

© Universidad Internacional de La Rioja (UNIR)

El NIST presenta **casos de uso** (por ejemplo, un proveedor de datos que desea compartir datos con consumidores y condiciona acceso bajo políticas, mecanismos de control de acceso, auditoría histórica del acceso, etc.) (NIST, s.f.). Además, el modelo distingue entre **amenazas** vinculadas a confidencialidad, **integridad, disponibilidad** y privacidad y las contrapartes en **controles** (NIST, s. f.). En resumen, el NIST propone una arquitectura referencial robusta para pensar dónde y cómo insertar mecanismos de seguridad dentro del ecosistema *big data.*

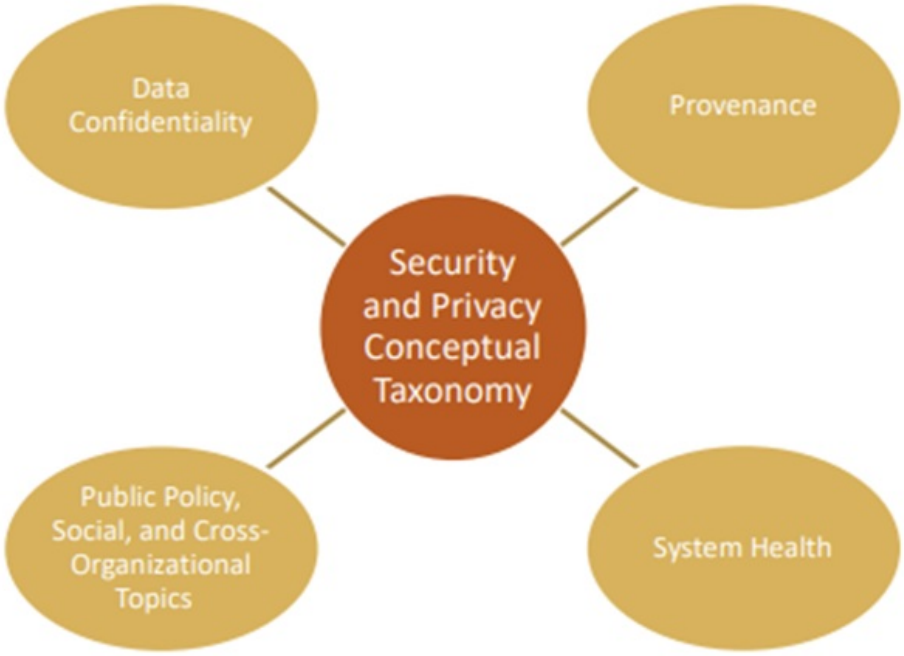


Figura 2. Taxonomía conceptual seguridad big data del NIST. Fuente: National Institute of Standars and Technology, 2019.

© Universidad Internacional de La Rioja (UNIR)

Ideas clave

Características de big data

Características del *big data* y su impacto en seguridad

Las llamadas **5 V** del *big data* (volumen, variedad, velocidad, veracidad, valor), implican **desafíos particulares** para la seguridad y privacidad:

- **Volumen**: grandes cantidades de datos dificultan la revisión manual, el control granular y el análisis forense.
- **Variedad**: coexistencia de datos estructurados, semiestructurados y no estructurados (texto, imágenes, vídeo, *logs*) exige mecanismos de seguridad que soporten múltiples formatos.
- **Velocidad/flujo continuo**: el procesamiento en tiempo real *(streaming)* exige mecanismos de cifrado, autenticación, autorización con baja latencia.
- **Veracidad/confianza**: la calidad y la integridad de los datos deben preservarse frente a ataques o manipulaciones.
- **Valor**: muchos datos son sensibles o contienen información personal, por lo que los controles de privacidad son críticos.

Además, el ecosistema *big data* está compuesto por múltiples **sistemas heterogéneos** (bases de datos, motores de análisis, *pipelines* de ingestión, API, interfaces de usuario), lo que introduce **múltiples vectores de ataque** de diversos componentes. Por ello, asegurar el *end-to-end* resulta más complejo que en sistemas tradicionales.

© Universidad Internacional de La Rioja (UNIR)

Ideas clave

Amenazas y riesgos típicos

Algunas **amenazas** clave en ecosistemas *big data:*

- **Acceso no autorizado** (usuarios, servicios).
- **Suplantación de identidad** de nodos, servicios o componentes *(spoofing).*
- **Intercepción de datos***(man in the middle)* durante la transmisión.
- Alteración/**manipulación de datos** en tránsito o reposo.
- **Exposición de metadatos** sensibles (nombre de tablas, esquemas, columnas) que pueden facilitar ataques de inferencia.
- **Ejecución de código malicioso** en *pipelines* de procesamiento (por ejemplo, *jobs* MapReduce, *scripts* UDF que contengan código dañino).
- Empleo de **nodos corruptos** o trabajadores maliciosos (*insiders* o nodos comprometidos).
- **Fallos de configuración,** permisos excesivos, roles mal segregados.
- **Amenazas internas:** administradores maliciosos o negligentes.
- **Riesgos de cumplimiento regulatorio** (protección de datos personales, privacidad).
- **Desbordamientos,** ataques de denegación de servicio, saturación de recursos.

© Universidad Internacional de La Rioja (UNIR)

1	Insecure Computation	Access Sensivite Data, Program Leads to Corrupt Data, DoS into Big Data Services
2	End Point Input Validation and Filtering	Trusting Data, Filtering Data
3	Granular Access Control	prevent of end user access data like in relational database
4	Insecure Data Storage and Communication	Data is distributed: authorization, authentication and encryption at each node Auto Tiering: Auto Partition and Moving Data Real Time Analytics / Continuous Computation: needs low latency, fast encryption/decryption Protection Transactional Log
5	Privacy Preserving Data Mining and Analytics	Issue of Invasion Privacy, Invasive Marketing, Disclose Sensitive Information

Figura 4. Vulnerabilidades *big data.* Fuente: Paryasto,2014.

Por ejemplo, en el artículo «Secure big data ecosystem architecture: challenges and solutions», los autores revisan dichos retos y señalan que muchas soluciones existentes se enfocan solo en **partes aisladas** del ecosistema, sin un **enfoque global** de **extremo a extremo** (Anwar,2021).

Otro trabajo, *Survey on Big Data Security Framework*, analiza cómo los **controles** se pueden agrupar en **niveles** (aplicación, red, clasificación de datos, análisis) y la importancia de cubrir múltiples niveles del *stack* de *big data* (Thangaraj y Balamurugan, 2017).

Asimismo, en «Privacy-preserving big data analytics: a comprehensive survey», los autores examinan los desafíos de mantener la **privacidad** cuando se analizan grandes volúmenes de datos con **múltiples partes interesadas** y **modelos colaborativos** (Tran, 2019).

Controles básicos y mecanismos de seguridad en arquitecturas big data

A continuación, se describen los **controles** más importantes que un sistema *big data* debe incorporar, alineados con el tejido de seguridad del modelo NIST.

© Universidad Internacional de La Rioja (UNIR)



Figura 4. Taxonomía operativa de seguridad *big data* del NIST. Fuente: National Institute of Standars and Technology, 2019.

Autenticación y gestión de identidad

Es necesario usar **sistemas de autenticación** *single sing on* combinados con el uso de mutual TLS:

- Uso de **sistemas robustos** de autenticación, como Kerberos, OAuth, OpenID Connect, certificados (TLS mutual).
- **Autenticación** mutua **entre nodos** (servicios internos) para evitar nodos suplantados.
- **Autenticación federada** cuando varios dominios o entidades externas participan como proveedores o consumidores de datos.

© Universidad Internacional de La Rioja (UNIR)

- Uso de *tokens* con **tiempo de vida limitado,** renovación y revocación.
- Integración con **directorios corporativos** (LDAP, Active Directory) para gestión centralizada de identidades.

Autorizar y controlar acceso

Control de acceso basado en **roles** (RBAC), en **atributos** (ABAC) o en **políticas** (PBAC):

- **Autorización a nivel de metadatos y datos:** limitación de acceso a tablas, columnas, filas *(row-level filtering)* y celdas *(cell-level).*
- **Políticas centralizadas** que se puedan aplicar en múltiples motores (almacenamiento, consulta, *streaming*).
- **Controles de separación de funciones** *(segregation of duties)* para evitar que un único rol autorice y también ejecute acciones críticas.
- **Reglas de acceso condicional** (por ejemplo, basadas en la ubicación de acceso, hora del día, dispositivo).
- Aplicación de **políticas de acceso dinámico** y ajustes en tiempo real según contexto o riesgo.

© Universidad Internacional de La Rioja (UNIR)

Cifrado y protección de datos

- **En tránsito:**
  - **User TLS/SSL** en todas las comunicaciones entre componentes (nodos, clientes, API).
  - **Cifrado en protocolos RPC, HTTP/REST,** canal de transporte de datos (por ejemplo, entre distribuidores de datos).
  - **Protección contra ataques** de tipo *man in the middle, downgrade* y cifrados débiles.
- **En reposo:** cifrado de datos almacenados (archivos, tablas, discos). Establecer zonas de cifrado *(encryption zones)* que aplican cifrado de forma transparente al acceso y combinadas con gestión de claves. Además:
  - **Criptografía de almacenamiento avanzado:** cifrado de columna, cifrado homomórfico parcial, cifrado basado en atributo (ABE).
  - **Gestión segura y robusta de las claves:** almacenamiento separado, rotación periódica, acceso controlado, respaldo seguro.
  - **Posible uso de cifrado híbrido** (combinando cifrado simétrico y asimétrico) para escalar mejor en entornos masivos.

Un estudio comparativo reciente de técnicas de cifrado en *big data* analiza opciones como DES, AES y RSA, evaluando *trade-offs* de seguridad versus rendimiento en contextos *big data* (Matta, 2021).

© Universidad Internacional de La Rioja (UNIR)

Auditoría, registro y trazabilidad

Para una correcta **auditoría,** es necesario registrar los accesos a los datos y ser consultados exclusivamente por el auditor del sistema:

- **Registro de eventos** de acceso, éxito/fracaso, cambios en políticas, modificaciones en datos, accesos administrativos.
- **Auditoría de accesos denegados** para detectar intentos de intrusión.
- **Trazabilidad del linaje de datos** *(data lineage)* para saber cómo se transformaron los datos, qué operaciones se aplicaron, por quién y cuándo.
- **Monitoreo de anomalías** (uso excesivo de recursos, patrones inusuales de acceso).
- **Integra mecanismos de forense de datos:** capturar evidencia digital, retención de *logs* a largo plazo, preservación de integridad de registros.

Privacidad, protección de datos sensibles y anonimización

Hay distintas **técnicas de privacidad** que son necesarias de aplicar en función del tipo y categoría de de los datos:

- **Técnicas de anonimización,** desidentificación, generalización, supresión, perturbación *(noise addition)* para proteger datos personales.
- Uso de **modelos de privacidad diferencial** *(differential privacy)* en consultas agregadas.
- Control del **acceso a datos sensibles** mediante políticas específicas, etiquetas de sensibilidad *(data labeling).*
- Evaluación de **riesgo de reidentificación** en los datos compartidos.

© Universidad Internacional de La Rioja (UNIR)

- **Aplicación de principios,** como privacidad por diseño *(privacy by design),* desde el inicio del sistema.
- En entornos colaborativos (múltiples organizaciones), **protocolos de compartición segura** *(data sharing),* cifrado funcional o basado en atributos.

Gestión de riesgos, gobernanza y cumplimiento

Es necesario integrar la arquitectura en el marco de un **sistemas de gestión de seguridad de la información:**

- **Identificación de los activos de datos,** clasificación del riesgo, valoración del daño potencial.
- **Aplicación de marcos de control** (por ejemplo, NIST RMF, ISO/IEC 27001, COBIT).
- **Políticas de retención y eliminación** de datos.
- **Evaluación de cumplimiento regulatorio** (por ejemplo, GDPR en Europa, leyes de privacidad locales).
- **Revisión periódica** de auditorías, gestión de incidentes y planes de recuperación.
- **Formacióny concienciación** del personal.

© Universidad Internacional de La Rioja (UNIR)

Integración del modelo NIST con mecanismos concretos: correspondencias y ejemplos

Una de las ventajas del enfoque NIST es que las recomendaciones del tejido de seguridad pueden mapearse a **controles concretos** del sistema *big data* y muchas implementaciones pueden alinearse con las fases/capas del modelo.

Mapeo de funciones NIST a controles técnicos

Por ejemplo:

- En la fase de **ingestión,** el tejido de seguridad exige autenticación del proveedor de datos, validación del origen, filtrado, cifrado del tránsito, control de acceso inicial.
- En **almacenamiento,** se aplican cifrados de disco o zonales, control de acceso granular, encriptado de columnas, auditoría de accesos de lectura/escritura.
- En la fase de **procesamiento/análisis,** se deben activar políticas de control de acceso en los motores (por ejemplo, Spark, Flink, Hive), verificar que los trabajos no ejecuten código malicioso, aplicar límites de recursos, aislamientos de contenedor.
- En la **presentación/visualización,** los resultados mostrados deben respetar las políticas de acceso, filtrar datos sensibles, aplicar anonimización si es necesario.
- A lo largo de todo el flujo, actúan los mecanismos de **auditoría, trazabilidad**, monitoreo, gestión de claves, políticas dinámicas.

© Universidad Internacional de La Rioja (UNIR)

Ejemplo: uso de zonificación cifrada *(encryption zones)* en sistemas tipo Hadoop

En una plataforma tipo Hadoop, uno puede definir **zonas cifradas** para carpetas o *datasets* específicos de modo que el cifrado se aplique de forma **transparente** al **usuario final** (lectura/escritura automática). Esa funcionalidad encaja bien en el tejido de seguridad del modelo NIST para el componente almacenamiento. La gestión de claves (KMS) debe operar con **controles estrictos, separación de funciones, auditoría de uso de claves.**

Los sistemas de autorización (por ejemplo, Apache Ranger, Apache Sentry) pueden aplicar políticas de acceso en **múltiples niveles** (tablas, columnas, filas) que corresponden al **control de acceso** del **tejido NIST** en fases de procesamiento/consulta.

Implementaciones y propuestas recientes

El artículo «Secure big data ecosystem architecture: challenges and solutions» ofrece un enfoque que integra múltiples mecanismos —autenticación, cifrado, segmentación de red, aislamiento de componentes, políticas de acceso— como una **arquitectura segura de extremo a extremo** (Anwar, 2021).

Otro trabajo, *Survey on Big Data Security Framework*, **analiza** diferentes **componentes** del *stack* de *big data* (ingestión, almacenamiento, consulta, analítica) y cómo las investigaciones recientes han tratado mecanismos de seguridad en cada capa (Thangaraj,2017).

Además, en el área de privacidad, el estudio *Privacy-preserving big data analytics: a comprehensive survey* presenta técnicas modernas adoptadas para **proteger** la **privacidad** en análisis a gran escala, como privacidad diferencial, agregación segura, esquemas criptográficos avanzados (Tran, 2019).

© Universidad Internacional de La Rioja (UNIR)

Desafíos, limitaciones y avances recientes

- **Rendimiento y escalabilidad:** implementar controles robustos (cifrado, autorización granular, auditoría extensiva) implica sobrecostes en CPU, latencia, uso de red y almacenamiento de metadatos. En escenarios de *streaming* en tiempo real, esos retrasos pueden no ser tolerables. Encontrar un balance entre seguridad y rendimiento es un desafío persistente.

- **Complejidad operativa y gestión:** la administración de claves, políticas de acceso, permisos, auditorías, segregación de funciones, actualizaciones de *software* y cohesión entre múltiples componentes heterogéneos, exige un nivel alto de operación y mantenimiento sofisticado.

- **Ecosistemas heterogéneos y componentes externos:** *big data* no es solo almacenamiento y procesamiento interno, sino que incluye ingestión, desde API externas, integración de microservicios, uso de contenedores, servicios de inteligencia artificial, servicios en la nube, etc. Cualquier componente externo que no esté debidamente asegurado, puede comprometer toda la plataforma.

- **Evolución de amenazas y ataques sofisticados:** los atacantes pueden emplear nodos maliciosos, ataques colaborativos, análisis de metadatos, ataques de inferencia, uso de aprendizaje automático adversarial, ataques de canal lateral *(side-channel),* etc. Se requieren mecanismos adaptativos y defensas dinámicas.

En particular, las **técnicas modernas** de privacidad *(preserving analytics)*, como el *machine learning* con privacidad diferencial, están en **constante evolución** (Tran y Hu, 2019).

© Universidad Internacional de La Rioja (UNIR)

Gobernanza, cumplimiento normativo y responsabilidad ética

El cumplimiento de regulación (por ejemplo, GDPR en la UE) obliga a **controles específicos** sobre datos personales, derechos de acceso, derecho al olvido, portabilidad, anonimización. Integrar estos requisitos con la arquitectura técnica es complejo. Además, la gobernanza del dato (quién puede decidir, quién puede acceder, trazabilidad de decisiones algorítmicas) es un **campo emergente** que exige marcos organizativos y técnicos bien diseñados.

Buenas prácticas recomendadas

Para una arquitectura *big data* segura (alineada con el modelo NIST y las mejores prácticas de la literatura):

- **Adoptar el enfoque *security and privacy by design:*** la seguridad debe integrarse desde el diseño del sistema, no añadirse después.
- **Tener una visión de extremo a extremo** *(end-to-end)* del flujo de datos y pensando en controles en cada punto (ingestión, almacenamiento, procesamiento, presentación).
- Aplicar el principio de **mínimos privilegios** *(least privilege)* en usuarios, roles y servicios.
- **Segregación clara de roles** (administradores de plataforma, operadores, analistas de datos) con controles de separación de funciones.
- Uso de **autenticación robusta** y **federada** con renovación y revocación de credenciales.
- **Cifrado fuerte en tránsito** y **en reposo** con una gestión de claves segura (rotación, división de funciones, auditoría).
- Implementar **mecanismos de acceso granular** (RBAC, ABAC, políticas dinámicas) que estén integrados con los motores de análisis y las API.

© Universidad Internacional de La Rioja (UNIR)

Ideas clave

- **Auditoría extensa** y **trazabilidad del linaje** de datos con capacidad de detectar anomalías y soporte forense.
- **Protección de la privacidad** mediante anonimización, privacidad diferencial y control de acceso a datos sensibles.
- Integrar **gobernanza de datos,** políticas de retención y eliminación, cumplimiento normativo y evaluación de riesgos.
- **Monitorización continua,** análisis de amenazas emergentes, actualización regular de componentes, pruebas de seguridad y revisiones *(pentesting).*
- **Pruebas de escalabilidad** para asegurarse de que los controles no introducen cuellos de botella.

© Universidad Internacional de La Rioja (UNIR)

10.3. Arquitecturas Hadoop

Hadoop es un sistema ampliamente utilizado para **almacenar, procesar** y **analizar** grandes volúmenes de **datos** distribuidos. Su arquitectura, que incluye componentes como HDFS, MapReduce/YARN, NameNode, DataNodes, etc., brinda gran escalabilidad, tolerancia a fallos y procesamiento paralelo, pero, al mismo tiempo, expone vectores de **ataque particulares** debido a:

- Su **naturaleza distribuida.**
- La **heterogeneidad** de los nodos.
- La existencia de **servicios múltiples** y API diversas.
- **Potencialexposición** de datos sensibles, metadatos y flujos internos.

En los últimos años, ha habido un incremento de **interés académico** y **práctico** en fortalecer la seguridad de Hadoop mediante investigaciones, mejores herramientas, integraciones con soluciones criptográficas, análisis de políticas de acceso, etc.

© Universidad Internacional de La Rioja (UNIR)

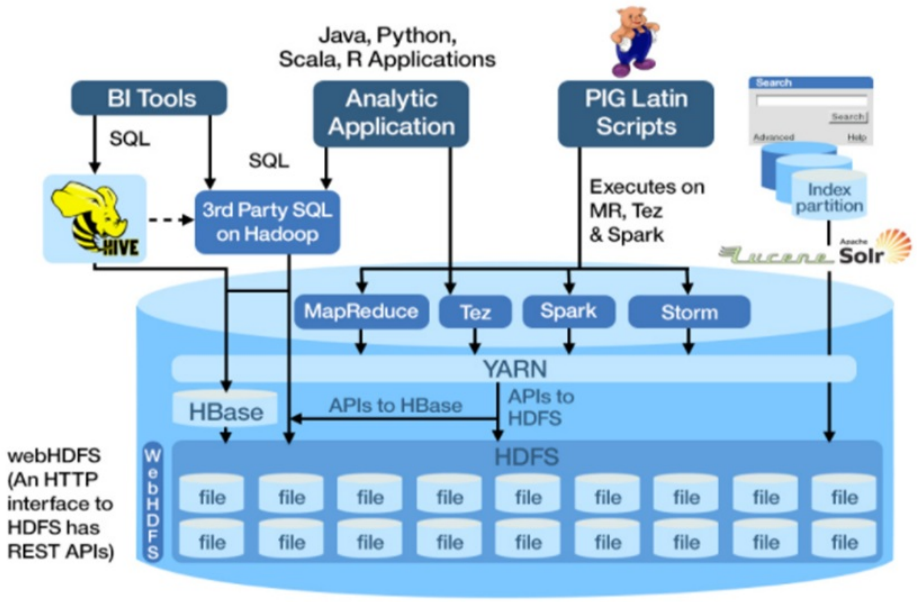


Figura 5. Arquitectura Hadoop. Fuente: Pragma Edge Software Services Private Limited, 2016.

Amenazas y riesgos principales

Las amenazas que se identifican con frecuencia en el contexto de Hadoop incluyen:

- **Usuarios/*authentication* comprometida:** uso de credenciales robadas, suplantación, ataques de *replay* o *dictionary* en Kerberos u otros mecanismos.
- **Acceso no autorizado** a datos sensibles, incluyendo filtraciones de metadatos.
- **Servicios maliciosos o nodos corruptos:** nodos que actúan maliciosamente, ya sea de forma aislada o colaborativa *(collusive workers)* para alterar resultados o robar datos (Sauber, Awad, Shawish, et. al., 2021).
- **Ejecución de código arbitrario:** los usuarios pueden subir o ejecutar *jar files* (MapReduce, Pig, Hive UDF) que podrían contener código malicioso (Begum, 2020).
- **Falta de cifrado o cifrado débil** tanto en reposo como en tránsito.

© Universidad Internacional de La Rioja (UNIR)

- **Configuraciones inseguras**, roles con permisos excesivos, falta de segregación.
- **Amenazas internas** y errores humanos.
- **Cumplimiento legal/regulatorio:** GDPR, protección de datos personales, privacidad.

Componentes de seguridad estándar en Hadoop

Estos son los **principales componentes** que se usan (o deberían usarse) para reforzar la seguridad:

- **Kerberos**: para autenticar servicios y usuarios mutuamente con *tickets* y *keytabs.* Permite que los nodos dentro de un clúster estén autenticados de forma segura (Begum, 2020).
- **Autorización** nativa en HDFS (permisos tipo POSIX, ACL) y herramientas externas, como Apache Ranger, Apache Sentry (Begum, 2021).
- ***Transparent encryption* (cifrado transparente) en HDFS** con zonas de cifrado *(encryption zones)* y uso de *key management server* (KMS) (Transparent Encryption in HDFS, s. f.).
- **Cifrado de datos en tránsito**: TLS/SSL en RPC, HttpFS, etc.
- ***Gateways/proxies* seguros**: por ejemplo, Apache Knox actúa como punto de entrada seguro para servicios HTTP/REST (Begum, 2020).
- **Auditoría/*logging* y trazabilidad:** registro de accesos, operaciones, borrados, denegaciones, etc.
- **Mejoras criptográficas y mecanismos de autenticación distribuida** recientes: propuestas que combinan criptografía moderna, firmas digitales, etc. (Hena, 2021).

© Universidad Internacional de La Rioja (UNIR)

Autenticación y autorización

Autenticación

El modo seguro de Hadoop requiere Kerberos para **autenticar** tanto **clientes** (usuarios) como **servicios** (NameNode, DataNode, ResourceManager, etc.). (Begum, 2020).

Recientemente, se han propuesto **mejoras** al **esquema de autenticación** para superar problemas, como el *single point of failure,* ataques de *replay,* sincronización de tiempo, etc. Por ejemplo, *Distributed authentication framework for Hadoop based bigdata environment* incorpora **firmas digitales, sistemas de umbral** *(threshold cryptosystems),* etc. (Hena, 2021).

Autorización

Recomendaciones para el **control de acceso:**

- **Permisos en HDFS:** propietario, grupo, otros; uso de ACL extendidas para mayor granularidad.
- **Políticas centralizadas** con herramientas, como Apache Ranger o Apache Sentry, que aplican reglas sobre quién tiene acceso a qué *datasets,* qué columnas, etc.
- **Controles más finos:** algunos trabajos muestran que los *frameworks* de análisis (Spark, etc.) requieren mecanismos extras para evitar que usuarios con permisos limitados evadan políticas mediante API. Ejemplo: *The Queen's Guard: A Secure Enforcement of Fine-grained Access Control in Distributed Data Analytics Platforms* (Shaon, 2021).

© Universidad Internacional de La Rioja (UNIR)

Ideas clave

Cifrado de datos

En reposo:

- ***Encryption zones*en HDFS:** directorios especiales cifrados automáticamente cuando se lee/escribe sin necesidad de cambiar la aplicación–cliente. Se usan claves gestionadas por KMS (Transparent Encryption in HDFS, s. f.).

- **KMS***(key management server):* implementa la gestión de claves de cifrado, versiones, versiones de claves, permisos sobre quién puede acceder a la clave, etc. (Transparent Encryption in HDFS, s. f.).

- **Empresas,** como Oracle, documentan implementaciones de *transparent encryption* habilitadas sobre clústeres Kerberos-*secured* (Security for Oracle Big Data Appliance, s. f.).

En tránsito:

- TLS/SSL para **comunicaciones entre nodos, clientes, API REST,** etc. Es necesario configurarlo adecuadamente para evitar ataques de *downgrade,* cifrados débiles, etc.

- Algunas distribuciones y servicios gestionados (por ejemplo, Amazon EMR) ya activan el **cifrado en tránsito** y en **reposo** al usar zonas cifradas y KMS Transparent encryption in HDFS on Amazon EMR, s. f.).

Auditoría, monitoreo y cumplimiento

Es necesario tener en cuenta recomendaciones y el uso de herramientas y servicios adecuados para implementar un correcto **registro** y **auditoría:**

- **Registro de *logs*/auditoría** de acceso, operaciones (lectura, escritura, eliminación), accesos denegados.

© Universidad Internacional de La Rioja (UNIR)

- Herramientas como Apache Ranger y Apache Atlas permiten políticas de a **uditoría centralizada, trazabilidad** *(lineage),* **metadatos** e **historiales** de quién hizo qué.
- **Monitoreo de anomalías:** nodos que consumen recursos extra, patrones de acceso inusuales, etc.
- **Evaluación del cumplimiento regulatorio:** protección de datos personales, privacidad, GDPR, leyes nacionales de privacidad y políticas de retención de datos.

Propuestas recientes de mejora e investigación

Algunos trabajos recientes que aportan enfoques nuevos se pueden consultar en la Tabla 1:

Artículo	Lo que aporta/propuesta	Ventajas principales	Limitaciones o desafíos restantes
Shrihari, M. R., Manjunath, T. N., Archana, R. A. y Hegadi, R. S. (2019). Research challenges in Big Data security with Hadoop platform. *Communications in Computer and Information Science, 1037*. Springer.	Revisión de retos existentes, identificación de gaps en herramientas de seguridad, cifrado, autorización, privacidad.	Buen panorama de los problemas; útil para establecer prioridades de investigación.	Algunos enfoques teóricos; implementación práctica limitada.
Rajeh, W. (2022). Hadoop distributed file system security challenges and examination of unauthorized access issue. *Journal of Information Security, 13*(2), 23-42.	Estudia específicamente el problema de accesos no autorizados en HDFS y analiza vectores de ataque y su impacto.	Actualizado, con ejemplos reales; destaca la necesidad de configuraciones fuertes.	Enfocado más en HDFS; menos atención a capas superiores, como procesamiento, API, servicios de usuario.
Hena, M. y Jeyanthi, N. (2021). Distributed authentication framework for Hadoop based bigdata environment. *Journal of Ambient Intelligence and Humanized Computing, 13*, 4397-4414.	Integra criptografía más moderna (firma digital, sistema de umbral, etc.) para superar puntos débiles del esquema tradicional basado en Kerberos.	Mejora la resistencia ante ciertos ataques y reduce la dependencia de punto único de fallo.	Complejidad añadida; costo computacional; necesidad de coordinación temporal y de configuración entre nodos.
Zine-Dine, F., Alcabnani, S., Azouaoui, A. y Kafi, J. E. (2025). Enhance big data security based on HDFS using the hybrid approach. *Indonesian Journal of Electrical Engineering and Computer Science, 38*(2), 1256.	Propone esquema híbrido de cifrado (AES + DES) para cifrar archivos en HDFS, desencriptándolos en tareas MapReduce.	Mejora la seguridad, aprovecha procesamiento distribuido; relativamente reciente.	DES es considerado débil comparado con algoritmos modernos; *overhead* posible; compatibilidad y mantenimiento del enfoque híbrido; riesgo de que DES sea un eslabón débil.

Tabla 1. Resumen de trabajos relevantes sobre seguridad en Big Data. Fuente: elaboración propia.

© Universidad Internacional de La Rioja (UNIR)

Casos prácticos de implementación

Algunas **implementaciones de Hadoop** importantes:

- ***Transparent encryption* en Hadoop 3.4.2:** versión reciente que implementa cifrado transparente en HDFS, zonas de cifrado, KMS, con versiones de claves (Transparent Encryption in HDFS, s. f.).
- **Amazon EMR**: incluye cifrado de datos en reposo e integración con KMS, uso de zonas de cifrado; algunas limitaciones, como movimiento de archivos entre zonas cifradas/no cifradas (Transparent encryption in HDFS on Amazon EMR, s. f.).
- **Oracle *big data appliance:*** implementación de cifrado transparente y KMS, separación física o lógica del servicio de gestión de claves *(key trustee)* (Security for Oracle Big Data Appliance, s. f.).
- **Azure HDInsight** es un servicio de análisis, de código abierto, espectro completo y totalmente administrado en la nube para empresas. Con HDInsight puede usar plataformas de código abierto, como Apache Spark, Apache Hive, LLAP, Apache Kafka, Hadoop, etc., en el entorno de Azure.

Desafíos abiertos y limitaciones

Como todas las arquitecturas y sistemas, siempre hay oportunidades de mejora en bases a las **limitaciones existentes** y los desafíos que se plantean.

- **Rendimiento/*overhead:*** cifrar y descifrar, autenticación robusta, auditoría continua, políticas finas (todos implican coste en CPU, latencia y ancho de banda). Evaluaciones muestran que hay *trade-offs* importantes.
- **Complejidad operativa:** configurar Kerberos, KMS, permisos, roles, configurar TLS, asegurar los nodos, gestionar certificados, sincronización de relojes, etc., pueden generar errores y vulnerabilidades si no se hace correctamente.

© Universidad Internacional de La Rioja (UNIR)

Ideas clave

- **Seguridad del ecosistema completo:** Hadoop no funciona solo, sino que hay muchos componentes (Hive, HBase, Spark, YARN, herramientas de ingestión, API REST, UIs…). Un eslabón débil, en alguno de ellos, puede comprometer toda la plataforma.
- **Políticas de acceso granulares vs. gestión:** definir reglas finas (por usuario, grupo, columna) mejora la seguridad, pero dificulta la administración, mantenimiento y escalabilidad.
- **Gestión de claves**: garantizar que las claves sean seguras, estén protegidas, rotadas, con acceso restringido; evitar que la clave maestra sea compromiso.
- **Evolución de amenazas:** *malware, insiders,* ataques de canal lateral *(side channel),* etc. Investigación todavía activa.

Conclusiones

La seguridad en arquitecturas *big data* basadas en Hadoop es una disciplina madura, con buenos componentes estándares (Kerberos, autorización, cifrado, auditoría), pero no exenta de riesgos.

Las investigaciones recientes proponen mejoras concretas: nuevos mecanismos de autenticación, cifrado híbrido, políticas más granulares, detección de trabajadores maliciosos, etc.

Implementaciones modernas, como Hadoop 3.4.2, Amazon EMR, Azure HDInsght u Oracle Big Data Appliance, ya incluyen muchas de estas características, pero siempre es necesario **configurarlas correctamente.**

Las **buenas prácticas operativas** (principio de mínimo privilegio, segregación de roles, actualización de *software,* auditoría continua) siguen siendo fundamentales.

© Universidad Internacional de La Rioja (UNIR)

10.4. Referencias bibliográficas

Anwar, M. J., Gill, A. Q., Hussain, F. K. e Imran, M. (2021). Secure big data ecosystem architecture: challenges and solutions. Journal on Wireless Communications and Networking, 2021(130). https://link.springer.com/article/10.1186/s13638-021-01996-2

Begum, G., Ul Huq, S. Z. y Siva Kumar, A. P. (2020). Sandbox security model for Hadoop file system. *Journal of Big Data, 7*(82). https://doi.org/10.1186/s40537-020-00356-z

Begum, G., Ul Huq, S. Z. y Siva Kumar, A. P. (2021). Security features in Hadoop—a survey. *Innovations in Computer Science and Engineering*, 171,269–276. https://doi.org/10.1007/978-981-33-4543-0_29

Boyd, D., Chang, W. y Levin, O. (2019). *NIST Big Data Interoperability Framework:*

Chang, W., Roy, A. y Underwood, M. (2019). NIST Big Data Interoperability Framework: Volume 4, Security and Privacy. National Institute of Standards and Technology. https://nvlpubs.nist.gov/nistpubs/SpecialPublications/NIST.SP.1500-4r2.pdf

Hena, M., Jeyanthi, N. (2022). Distributed authentication framework for Hadoop based bigdata environment. *Journal of Ambient Intelligence and Humanized Computing, 13*, 4397–4414. https://doi.org/10.1007/s12652-021-03522-0

Matta, P., Arora, M. y Sharma, D. (2021). A comparative survey on data encryption techniques: Big data perspective. Materials Today: Proceedings, 46(20), 11035-11039. https://www.sciencedirect.com/science/article/abs/pii/S2214785321012153

© Universidad Internacional de La Rioja (UNIR)

Paryasto, M., Alamsyah, A. y Rahardjo, B. (2014). *Big-Data Security Management Issues* [conferencia]. International Conference on Information and Communication Technology, Bandung, Indonesia. https://www.researchgate.net/publication/263162698_Big-Data_Security_Management_Issues

Pragma Edge Software Services Private Limited. (2016). https://www.indiamart.com/pragma-edge-software-services-private-limited/photos.html

Rajeh, W. (2022). Hadoop distributed file system security challenges and examination of unauthorized access issue. *Journal of Information Security*, *13*(02), 23–42. https://doi.org/10.4236/jis.2022.132002

Sauber, A. M., Awad, A., Shawish, A. F. y El-Kafrawy, P. (2021). A novel Hadoop security model for addressing malicious collusive workers. *Computational Intelligence and Neuroscience.* https://doi.org/10.1155/2021/5753948

Security for Oracle Big Data Appliance. (2021). https://docs.oracle.com/en/bigdata/big-data-appliance/5.1/bigug/secure.html?utm_source=chatgpt.com#GUID-48584C66-5B52-42C4-A2A3-DEAD62185967

Shaon, F., Rahaman, S. y Kantarcioglu, M. (2021). *The Queen's Guard: a secure enforcement of fine-grained access control in distributed data analytics platforms.* Proceedings of the 39th Annual Computer Security Applications Conference, 241-255.

Shrihari, M. R., Manjunath, T. N., Archana, R. A., Hegadi, R. S. (2019). *Research challenges in Big Data security with Hadoop platform* [conferencia]. Recent Trends in Image Processing and Pattern Recognition Second International Conference, RTIP2R 2018, Solapur, India. https://doi.org/10.1007/978-981-13-9187-3_49

© Universidad Internacional de La Rioja (UNIR)

Thangaraj, M. y Balamurugan, S. (2017). *Survey on Big Data security framework* [conferencia]. Knowledge Management in Organizations 12th International Conference, KMO 2017, Beijing, China. https://doi.org/10.1007/978-3-319-62698-7_39

Tran, H. Y. y Hu, J. (2019). Privacy-preserving big data analytics a comprehensive survey. Journal of Parallel and Distributed Computing, 134, 207-218. https://www.sciencedirect.com/science/article/abs/pii/S0743731519300589?via%3Dihub

Transparent encryption in HDFS on Amazon EMR. (s. f.). https://docs.aws.amazon.com/emr/latest/ReleaseGuide/emr-encryption-tdehdfs.html?utm_source=chatgpt.com

Transparent Encryption in HDFS. (s. f.). https://hadoop.apache.org/docs/stable/hadoop-project-dist/hadoop-hdfs/TransparentEncryption.html?utm_source=chatgpt.com

Volume 6, Reference Architecture. National Institute of Standards and Technology. https://nvlpubs.nist.gov/nistpubs/SpecialPublications/NIST.SP.1500-6.pdf

Zine-Dine, F., Alcabnani, S., Azouaoui, A. y El Kafi, J. (2025). Enhance big data security based on HDFS using the hybrid approach. *Indonesian Journal of Electrical Engineering and Computer Science, 38*(2), 1256. https://www.researchgate.net/publication/391351963_Enhance_big_data_security_based_on_HDFS_using_the_hybrid_approach

© Universidad Internacional de La Rioja (UNIR)

Amazon Elastic Map Reduce

Amazon EMR 2.x and 3.x AMI versions. (2022). http://docs.aws.amazon.com/ElasticMapReduce/latest/DeveloperGuide/emr-what-is-emr.html

Permite analizar y procesar grandes cantidades de datos mediante la distribución del trabajo de cómputo a través de un clúster de servidores virtuales. El clúster es gestionado bajo la plataforma Hadoop, donde un nodo es designado como maestro para controlar la distribución de tareas.

© Universidad Internacional de La Rioja (UNIR)

Microsoft Azure HDInsight

¿Qué es Azure HDInsight? (2022). https://learn.microsoft.com/es-es/azure/hdinsight/hdinsight-overview

Permite usar el sistema de archivos distribuido Apache Hadoop (HDFS), la administración de recursos de Apache Hadoop YARN y un modelo de programación sencillo de MapReduce para procesar y analizar datos por lotes en paralelo.

© Universidad Internacional de La Rioja (UNIR)

Implementación de seguridad en Hadoop con Apache Ranger

Apache Ranger™. (s. f.). https://ranger.apache.org/

Ofrece un marco de seguridad centralizado para gestionar el control de acceso sobre componentes de Hadoop de acceso a datos, como Hive y Hbase, etc.

© Universidad Internacional de La Rioja (UNIR)

Apache Knox Gateway

REST API and Application Gateway for the Apache Hadoop Ecosystem. (s. f.). https://knox.apache.org/

Apache Knox consiste en un REST API Gateway para interactuar con los clústeres de Hadoop. Proporciona un solo punto de acceso para todas las interacciones REST con clústeres Hadoop. Además, facilita la funcionalidad de control, integración, monitorización y automatización de las necesidades críticas y analíticas de la empresa. Proporciona funciones de autenticación, autorización y auditoría.

© Universidad Internacional de La Rioja (UNIR)

Proyecto Rhino

Rhino. (s. f.). https://rhino.github.io/

Sirve a Hadoop como una solución completa que también soporta herramientas, como ZooKeeper, Hive, Oozie etc. Algunos de los beneficios de Rhino es que añade soporte de encriptación y gestión de claves, crea un marco común de autorización de Hadoop, inicia una única sesión, con autenticación basada en *token* y extiende el soporte de HBase para implementar listas de control de acceso (ACL) de forma más granular. Además, mejora el registro de auditoría.

© Universidad Internacional de La Rioja (UNIR)

Test

1. ¿Cuál es el propósito principal del modelo de referencia del NIST para *big data*?

A. Ejecutar consultas SQL sobre grandes volúmenes de datos.

B. Proporcionar una base común para el desarrollo seguro de arquitecturas *big data.*

C. Gestionar clústeres de procesamiento de datos en la nube.

D. Proveer herramientas gráficas para visualizar datos masivos.

2. ¿Cuál de las siguientes no es una característica del *big data* según las 5V?

A. Volumen.

B. Velocidad.

C. Veracidad.

D. Validación.

3. ¿Qué componente del modelo NIST representa la infraestructura tecnológica subyacente?

A. Proveedor de datos.

B. Plataforma de *big data.*

C. Sistema de *big data.*

D. Consumidor de datos.

4. ¿Cuál de los siguientes mecanismos de autenticación se utiliza en Hadoop para entornos seguros?

A. JWT (JSON web *tokens*).

B. OAuth 2.0.

C. Kerberos.

D. SAML.

© Universidad Internacional de La Rioja (UNIR)

5. ¿Qué componente del ecosistema Hadoop se encarga del almacenamiento distribuido?

A. YARN.

B. MapReduce.

C. HDFS.

D. Hive.

6. ¿Cuál es el propósito principal de Apache Ranger en Hadoop?

A. Ejecutar procesos de análisis de datos.

B. Gestionar metadatos de bases de datos.

C. Administrar políticas de seguridad y control de acceso.

D. Almacenar archivos grandes en clústeres.

7. ¿Qué tipo de cifrado protege los datos que se están moviendo por la red?

A. Cifrado en reposo.

B. Cifrado en tránsito.

C. Cifrado simétrico.

D. Cifrado de respaldo.

8. ¿Cuál de los siguientes es un riesgo común en sistemas *big data*?

A. Limitación de conectividad entre nodos.

B. Inexistencia de datos estructurados.

C. Superficie de ataque amplia por distribución del sistema.

D. Escalabilidad excesiva.

© Universidad Internacional de La Rioja (UNIR)

9. ¿Qué mecanismo de control de acceso sugiere el NIST para limitar permisos según funciones?

A. ABAC.

B. IAM dinámico.

C. RBAC.

D. Biometría.

10. ¿Qué componente del ecosistema Hadoop se encarga de la gestión de recursos?

A. HDFS.

B. Hive.

C. YARN.

D. Pig.

© Universidad Internacional de La Rioja (UNIR)